

## SPRINT 3

### Nivell 1: Entorn i Ingesta Híbrida (Code-First)

#### Exercici 1: Arquitectura de Dades (Lògica vs. Física)

Proyecto nuevo

---



Tienes 12 projects restantes en tu cuota. Solicita un incremento o borra algunos proyectos. [Más información](#)

[Manage Quotas](#)

Nombre del proyecto \*

ID del proyecto: sprint3-analytics-adrian. No se puede cambiar más adelante.

[Editar](#)


Recurso superior \*

[Explorar](#)

Selecciona la organización o carpeta en la que se creará este recurso

[Crear](#) [Cancelar](#)

He creat el projecte i he posat el meu nom.



Per crear el dataset utilitzant UI anem als 3 punts que hi ha al nostre projecte i creem el dataset.

ID del proyecto \*

sprint3-analytics-adrian

Cambiar

ID de conjunto de datos \*

sprint3\_bronze

Puede incluir letras, números y guiones bajos

Ubicación de los datos

EU (múltiples regiones en la Unión Europea)

▼ ?

Li poso el nom i l'ubicació a l'EU per després no tenir problemes amb l'ubicació d'altres fitxers i que no hi hagi costos de transferència.

🔍 Consulta sin título

Ejecutar

Guardar ▼

Programa

Compartir ▼

Archivo

Editar

Ejecutar

Herramientas

```
1 CREATE SCHEMA IF NOT EXISTS `sprint3-analytics-adrian.sprint3_silver`  
2 OPTIONS(  
3 | location = 'EU'  
4 );|
```

✅ Esta consulta procesará 0 B cuando se ejecute.

✅ Se completó la consulta

Recientes

Resultados de la consulta

Chat

View all jobs

Guardar los resultados ▼

Abrir en ▼

↕

✕

▼ 10:37 a.m.

Información del trabajo

Resultados

Detalles de la ejecución


Gráfico de ejecución

✅ CREATE SCHEMA IF N...

Se creó el conjunto de datos llamado sprint3\_silver.

Ir al conjunto de datos

Pel segon punt, obrim una consulta i posem aquest codi. En primer lloc, utilitzem el CREATE SCHEMA posant el nom del projecte seguit del nom del nou dataset. A continuació, donant l'opció de l'ubicació a EU, com abans.



```
adrianlorentetejero@cloudshell:~ (sprint3-analytics-adrian)$ bq mk --location=EU --dataset sprint3-analytics-adrian:sprint3_gold
Dataset 'sprint3-analytics-adrian:sprint3_gold' successfully created.
```

Pel tercer punt, obrim el cloud shell polsant l'icona que té aquest símbol “>\_”. Després, executem aquest codi també especificant l'ubicació a l'EU.

## Exercici 2: Ingesta en Capa Bronze (Connexió DDL)

```
1 CREATE OR REPLACE EXTERNAL TABLE `sprint3_bronze.transactions_raw`
2 OPTIONS (
3   format = 'CSV',
4   uris = ['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],
5   field_delimiter = ';'
6 );
```

▶ Canalizaciones

▶ Conexiones

▼ sprint3\_bronze

american\_users\_raw

companies\_raw

credit\_cards\_raw

european\_users\_raw

transactions\_raw

Mostrar más

Se completó la consulta

11:17 a.m.

CREATE OR REPLACE E...

CREATE OR REPLACE E...

CREATE OR REPLACE E...

CREATE OR REPLACE E...

CREATE OR REPLACE E...

CREATE OR REPLACE E...

Tiempo transcurrido

5 s

Declaraciones procesadas

5

Estado del trabajo

SUCCESS

Estado

Hora de finalización

SQL

Acción

✓

11:17 a.m. [1:1]

CREATE OR REPLACE EXTERNAL TABLE `sprint3\_bronze.transactions\_raw`

Ver resultados

✓

11:17 a.m. [7:1]

CREATE OR REPLACE EXTERNAL TABLE `sprint3\_bronze.companies\_raw`

Ver resultados

✓

11:17 a.m. [20:1]

CREATE OR REPLACE EXTERNAL TABLE `sprint3\_bronze.american\_users\_raw`

Ver resultados

✓

11:17 a.m. [26:1]

CREATE OR REPLACE EXTERNAL TABLE `sprint3\_bronze.european\_users\_raw`

Ver resultados

✓

11:17 a.m. [32:1]

CREATE OR REPLACE EXTERNAL TABLE `sprint3\_bronze.credit\_cards\_raw`

Ver resultados

En primer lloc tenim la consulta de la taula “transactions”. S'utilitza el CREATE OR REPLACE EXTERNAL TABLE, es posa el nom del dataset al que va destinat i el nom de la taula. Com a opcions, seguint el que ens indica a la taula de l'exercici, li posem el format, l'URI que ens donen i en aquest cas que es delimiti per “;”. Després està la captura on es veu que s'executen correctament les taules.

## Exercici 3: Càrrega de Dades Locals (Upload)

▼ Consultas

▶ Consultas compartidas

Consulta ex 1 ☆

Consulta ex 2 ☆

▶ Notebooks

▶ Lienzos de datos

▶ Preparaciones de datos

▶ Canalizaciones

▶ Conexiones

▼ sprint3\_bronze ☆

▼ sprint3\_bronze ☆

american\_users\_raw ☆

companies\_raw ☆

credit\_cards\_raw ☆

european\_users\_raw ☆

products\_raw ☆

transactions\_raw ☆

Crear tabla

Create ML model

Crear gráfico

Compartir ▶

Copiar ID

Actualizar contenido

Borrar

Fuente

Create table from 

Subir

Seleccionar archivo \* 

N1-Ex.8\_products.csv

Formato del archivo 

CSV

Destino

Proyecto \* 

sprint3-analytics-adrian

Conjunto de datos \* 

sprint3\_bronze

Tabla \* 

products\_raw

El tamaño máximo del nombre es de 1,024 bytes UTF-8. Se permiten letras, signos, números, conectores, guiones y espacios Unicode.

Tipo de tabla 

Tabla nativa

CREATE OR

En primer lloc, anem al dataset de bronze i creem la nova taula.  
Pugem l'arxiu, li posem el nom i ens assegurem que sigui nativa.

## Exercici 4: Arquitectura i Rendiment. Materialització de Dades (Assistit per IA)

### a) Materialització de Dades (Assistit per IA)

Li he fet el prompt al Gemini del BigQuery i he executat la query que m'ha suggerit.

Write a SQL query to create a new table called transactions\_raw\_native in the sprint3\_bronze dataset. It should contain all data from the transactions\_raw table. Please use CREATE OR REPLACE TABLE so I don't get errors if I run it more than once.

Mostrar razonamiento ▼

I've proposed a query to create the `transactions_raw_native` table by selecting all data from your existing `transactions_raw` table.

```
CREATE OR REPLACE TABLE `sprint3-analytics-adrian.sprint3_bronze.transactions_raw_native` AS SELECT * FROM `sprint3-analytics-adrian.sprint3_bronze.transactions_raw`;
```

1 `CREATE OR REPLACE TABLE `sprint3-analytics-adrian.sprint3_bronze.transactions_raw_native``

2 `AS`

3 `SELECT * FROM `sprint3-analytics-adrian.sprint3_bronze.transactions_raw`;`

4

5

Se completó la consulta

Recientes

Resultados de... 

Abrir en ▼

▼ 11:50 a.m.

✓ CREATE OR REPLACE T...

Información del trabajo

Resultados

Detalles de...

1

Esta declaración creó una nueva tabla con el nombre transactions\_raw\_native.

Ir a la tabla

## b) Auditoria de costos

Taula externa

```
1 SELECT id
2 FROM `sprint3_bronze.transactions_raw`;
```

|                  |          |
|------------------|----------|
| Bytes procesados | 12.61 MB |
| Bytes facturados | 13 MB    |

Taula nativa

```
1 SELECT id
2 FROM `sprint3_bronze.transactions_raw_native`;
```

|                  |         |
|------------------|---------|
| Bytes procesados | 3.62 MB |
| Bytes facturados | 10 MB   |

En conclusió, són més lleugeres les consultes a taules natives, ja que, a diferència de les externes, en les que ha de llegir tot el fitxer, en aquestes només llegeix la columna id.

## c) El perill del LIMIT

```
1 SELECT id
2 FROM `sprint3_bronze.transactions_raw_native`
3 LIMIT 10;
```

✓ Esta consulta procesará 3.62 MB cuando se ejecute.

Processarà la mateixa quantitat de B perquè abans d'aplicar el LIMIT llegeix tota la columna perquè a l'ordre d'execució de comandes el LIMIT va l'últim.

## Exercici 5: Adaptació de Sintaxi (Reporting)

```
1 SELECT DATE(TIMESTAMP(timestamp)) AS dia, ROUND(SUM(SAFE_CAST(amount AS FLOAT64)), 2) AS ingressos
2 FROM `sprint3-bronze.transactions_raw_native`
3 WHERE EXTRACT(YEAR FROM TIMESTAMP(timestamp)) = 2021
4 GROUP BY dia
5 ORDER BY ingressos DESC
6 LIMIT 5;|
```

✓ Esta consulta procesará 1.53 MB cuando se ejecute.

| Fila | dia        | ingressos |
|------|------------|-----------|
| 1    | 2021-10-27 | 11440.81  |
| 2    | 2021-01-22 | 11328.84  |
| 3    | 2021-02-11 | 11182.16  |
| 4    | 2021-04-29 | 11119.01  |
| 5    | 2021-03-27 | 10898.51  |

Seleccionem la taula nativa de “transactions”. Com que la columna “timestamp” té format string, el transformem a TIMESTAMP i amb la funció DATE treiem l'hora. He fet un ROUND per deixar-ho més net. Amb la funció SAFE\_CAST (així accepta NULL) transformem amount a números decimals. Després filtrem per any = 2021 amb la funció EXTRACT(YEAR FROM TIMESTAMP), s'agrupa per dia, es sumen els ingressos de cada dia, s'ordenen de major a menor i es limiten.

## Exercici 6: Consultes Complexes

```
1 SELECT c.company_name AS nom, c.country AS pais, t.timestamp AS data_transaccio, SAFE_CAST(t.amount AS FLOAT64) AS ingressos
2 FROM `sprint3-bronze.transactions_raw_native` t
3 JOIN `sprint3-bronze.companies_raw` c
4 ON t.business_id = c.id
5 WHERE SAFE_CAST(t.amount AS FLOAT64) BETWEEN 100 AND 200 AND DATE(TIMESTAMP(t.timestamp)) IN ('2015-04-29', '2018-07-20', '2024-03-13');
```

✓ Esta consulta procesará 2.29 MB cuando se ejecute.

Se está usando la cuota de procesamiento según demanda

> Resultados de la consulta

Chat

View all jobs

Guardar los resultados

Abrir en



| Información del trabajo | Resultados            | Visualización  | JSON                    | Detalles de la ejecución | Gráfico de ejecución |
|-------------------------|-----------------------|----------------|-------------------------|--------------------------|----------------------|
| Fila                    | nom                   | pais           | data_transaccio         | ingressos                |                      |
| 1                       | Fusce Corp.           | United States  | 2018-07-20 02:40:13 UTC | 114.77                   |                      |
| 2                       | Auctor Mauris Vel LLP | United States  | 2015-04-29 11:04:13 UTC | 181.42                   |                      |
| 3                       | Non Magna LLC         | United Kingdom | 2015-04-29 13:28:12 UTC | 178.1                    |                      |
| 4                       | Donec Fringilla PC    | France         | 2015-04-29 06:37:02 UTC | 187.52                   |                      |
| 5                       | Magna Incorporated    | New Zealand    | 2018-07-20 07:41:52 UTC | 144.16                   |                      |
| 6                       | Ac Libero Inc.        | United Kingdom | 2024-03-13 14:03:13 UTC | 172.88                   |                      |

He usat, com abans, les funcions SAFE\_CAST i DATE(TIMESTAMP). Primer, hem juntat les taules “transactions” i “companies”. He filtrar els ingressos entre 100 i 200 i pels 3 dies específics.

## Nivell 2: Neteja i Transformació (ELT)

### Exercici 1: Neteja de Productes (Data Quality)

```
1 CREATE OR REPLACE TABLE `sprint3_silver.products_clean` AS
2 SELECT
3   CAST(id AS STRING) AS product_id,
4   product_name AS name,
5   CAST(REPLACE(warehouse_id, 'WH-', '' ) AS INT64) AS warehouse_id,
6   SAFE_CAST(REGEXP_REPLACE(CAST(price AS STRING), r'^\d.', '' ) AS FLOAT64) AS price,
7   weight,
8   colour
9 FROM `sprint3_bronze.products_raw`;
```

 sprint3\_silver ☆ ⋮  Esta consulta procesará 5.53 KB cuando se ejecute.

 products\_clean ☆ ⋮

En primer lloc, seleccionem el dataset silver per a que sigui la seva destinació. Després, al SELECT en aquest cas he usat CAST per “id” perquè al tractar-se de la PRIMARY KEY no hi pot haver NULL, ens assegurem que el format és STRING i el renombram “product\_id”. “product\_name” el renombram “name”. Utilitzem la funció REPLACE per canviar “WH-” per res i al número que queda el posem en format de número enter. Amb el REGEXP\_REPLACE fem que al preu només sorti el número i el deixem amb format decimal. I “weight” i “colour” els deixem tal qual.

### Exercici 2: Creació de Transaccions Netes (Capa Silver)

```
1 CREATE OR REPLACE TABLE `sprint3_silver.transactions_clean` AS
2 SELECT
3   id AS transaction_id,
4   IFNULL(SAFE_CAST(amount AS FLOAT64), 0.0) AS amount,
5   SAFE_CAST(declined AS INT64) AS declined,
6   SAFE_CAST(lat AS FLOAT64) AS lat,
7   SAFE_CAST(longitude AS FLOAT64) AS longitude,
8   SAFE_CAST(timestamp AS TIMESTAMP) AS timestamp,
9   card_id,
10  business_id,
11  user_id,
12  ARRAY(
13    SELECT SAFE_CAST(TRIM(p_id) AS INT64)
14    FROM UNNEST(SPLIT(product_ids, ',')) AS p_id
15  ) AS product_ids
16 FROM `sprint3_bronze.transactions_raw_native`;
```

 Se completó la consulta

▼  sprint3\_silver ☆ ⋮

 products\_clean ☆ ⋮

 transactions\_clean ☆ ⋮

Com hem estat fent, amb el SAFE\_CAST canviem el format permetint NULL. El IFNULL el fem servir per a que en cas de ser NULL possi 0.0. Després, on fem l'ARRAY, en primer lloc utilitzem SPLIT per una cadena de text separada per comes en una llista i amb UNNEST agafem cada número de la llista per separat. A continuació el TRIM elimina els espais en blanc, amb el SAFE\_CAST transformem els elements en números enters i així formem l'ARRAY.

## Exercici 3: Unificació d'Usuaris (UNION)

```
1 CREATE OR REPLACE TABLE `sprint3_silver.users_combined` AS
2 SELECT
3   CAST(id AS STRING) AS user_id, name, surname, phone, email, birth_date, country, city, postal_code, address, 'EEUU' AS origin
4 FROM `sprint3_bronze.american_users_raw`
5
6 UNION ALL
7
8 SELECT
9   CAST(id AS STRING) AS user_id, name, surname, phone, email, birth_date, country, city, postal_code, address,
10  'Europa' AS origin
11 FROM `sprint3_bronze.european_users_raw`;
```

Se completó la consulta

sprint3\_silver

products\_clean

transactions\_clean

users\_combined

Aquí estem creant una taula per la unió de 2 querys. Hem deixat tal qual totes les columnes, excepte "id", que amb CAST (no fa falta SAFE, perquè es una PRIMARY KEY) li donem format de STRING. A més, hem creat una taula calculada ("origin"), on surt d'on són els usuaris.

## Exercici 4: Materialització de Companyies i Targetes de Crèdit

```
1 CREATE OR REPLACE TABLE `sprint3_silver.companies_clean` AS
2 SELECT id AS company_id, company_name, phone, email, country, website
3 FROM `sprint3_bronze.companies_raw`;
```

He creat taules a partir de les que ja existien i he canviat "id" per "company\_id" i "card\_id" per a que no sigui ambigu.

Se completó la consulta

sprint3\_silver

companies\_clean

credit\_cards\_clean

```
1 CREATE OR REPLACE TABLE `sprint3_silver.credit_cards_clean` AS
2 SELECT id AS card_id, user_id, iban, pan, pin, cvv, track1, track2, expiring_date
3 FROM `sprint3_bronze.credit_cards_raw`;
```

Esta consulta procesará 0 B cuando se ejecute.

# Nivell 3: Presentació de Dades i Creació de Vistes

## Exercici 1: La Vista de Màrqueting (Lògica de Negoci)

```
1 CREATE OR REPLACE VIEW `sprint3_gold.v_marketing_kpis` AS
2 SELECT c.company_name AS nom,c.phone AS telefon,c.country AS pais,ROUND(AVG(t.amount), 2) AS mitjana_ingressos,
3 CASE
4   WHEN AVG(t.amount) > 260 THEN 'Premium'
5   ELSE 'Standard'
6 END AS client_tier
7 FROM `sprint3_silver.companies_clean` c
8 JOIN `sprint3_silver.transactions_clean` t
9   ON c.company_id = t.business_id
10 GROUP BY c.company_id, c.company_name, c.phone, c.country;
```

✓ Se completó la consulta

Es crea la vista, s'agrupa per companyia (i per la resta de columnes que volem mostrar que no siguin calculades, per bones pràctiques), es calcula la mitjana d'"amount" i es crea una columna amb el tipus de client segons la mitjana d'"amount".

```
1 SELECT *
2 FROM `sprint3_gold.v_marketing_kpis`
3 ORDER BY
4   CASE WHEN client_tier = 'Premium' THEN 1 ELSE 2 END,
5   mitjana_ingressos DESC;
```

✓ Esta consulta procesará 1.53 MB cuando se ejecute.

Se está usando la cuota de procesamiento según demanda

> Resultados de la consulta

Chat

View all jobs

Guardar los resultados ▾

| Información del trabajo |                           | Resultados     | Visualización | JSON              | Detalles de la ejecución | Gráfico de ejecución |
|-------------------------|---------------------------|----------------|---------------|-------------------|--------------------------|----------------------|
| Fila                    | nom                       | telefon        | pais          | mitjana_ingressos | client_tier              |                      |
| 1                       | Ac Fermentum Incorporated | 06 85 56 52 33 | Germany       | 284.87            | Premium                  |                      |
| 2                       | Pretium Neque Corp.       | 07 77 48 55 28 | Australia     | 276.16            | Premium                  |                      |
| 3                       | Urna Convallis Associates | 06 01 24 77 04 | United States | 274.24            | Premium                  |                      |
| 4                       | At Associates             | 09 56 61 10 65 | New Zealand   | 272.21            | Premium                  |                      |

Ordenem la consulta, que amb la funció CASE THEN 1 ELSE 2 END li estem donant prioritats, en aquest cas, a "Premium", i després, ho ordenem per mitjana d'ingressos, així s'ordena dins de cada categoria.


## Exercici 2: Rànquing de Productes (La Potència dels Arrays)

```
1 CREATE OR REPLACE TABLE `sprint3_gold.product_sales_ranking` AS
2 WITH tabla_unnest AS (
3   SELECT t.transaction_id,prod_id
4   FROM `sprint3_silver.transactions_clean` t,
5   UNNEST(t.product_ids) AS prod_id
6 )
7 SELECT p.product_id, p.name, p.price, p.colour, COUNT(tu.transaction_id) AS total_sold
8 FROM `sprint3_silver.products_clean` p
9 LEFT JOIN tabla_unnest tu
10   ON CAST(p.product_id AS INT64) = tu.prod_id
11 GROUP BY p.product_id, p.name, p.price, p.colour
12 ORDER BY total_sold DESC;
```

✓ Se completó la consulta

Es crea una taula temporal amb WITH que amb UNNEST dividim els product\_ids en files. Aquesta taula la juntem amb “products\_clean” a l’esquerre per no perdre els productes que no s’han venut. Per juntar-les hem de canviar el format de product\_id per a que tingui el mateix format que prod\_id. Per finalitzar agrupem els productes per contar les seves transaccions.

## Exercici 3: Exportació de Resultats




The screenshot shows the Google Cloud BigQuery console. At the top, there's a query editor with the following SQL code:

```
1 SELECT *
2 FROM `sprint3_gold.product_sales_ranking`;
```

Below the query editor, a status bar indicates "Se completó la consulta" (Query completed). To the right, a dropdown menu for export options is visible, showing options like "JSONL (delimitado por líneas nuevas)", "Hojas de cálculo de Google", "CSV", and "JSON".

The main section displays the "Resultados de la consulta" (Query results). It includes a table with the following columns: product\_id, name, price, and colour. The results are as follows:

| Fila | product_id | name                | price  | colour  |
|------|------------|---------------------|--------|---------|
| 1    | 52         | riverlands the duel | 31.52  | #727272 |
| 2    | 29         | Tully maester Tarly | 167.2  | #111111 |
| 3    | 21         | duel Direwolf       | 96.9   | #e2e2e2 |
| 4    | 16         | the duel warden     | 180.91 | #666666 |



The screenshot shows the Google Sheets interface with the exported data. The data is organized into columns: #, product\_id, name, price, colour, #, total\_sold. The data rows are as follows:

|    | # | product_id | name                 | price  | colour  | # | total_sold |
|----|---|------------|----------------------|--------|---------|---|------------|
| 1  |   |            |                      |        |         |   |            |
| 2  |   | 52         | riverlands the duel  | 31.52  | #727272 |   | 2654       |
| 3  |   | 29         | Tully maester Tarly  | 167.2  | #111111 |   | 2635       |
| 4  |   | 21         | duel Direwolf        | 96.9   | #e2e2e2 |   | 2609       |
| 5  |   | 16         | the duel warden      | 180.91 | #666666 |   | 2608       |
| 6  |   | 66         | mustafar jinn        | 2.12   | #545454 |   | 2601       |
| 7  |   | 87         | sith Jade            | 96.26  | #e2e2e2 |   | 2598       |
| 8  |   | 33         | duel warden          | 127.09 | #191919 |   | 2597       |
| 9  |   | 48         | rock Renly in        | 21.53  | #9e9e9e |   | 2597       |
| 10 |   | 23         | riverlands north     | 169.96 | #545454 |   | 2593       |
| 11 |   | 68         | Stark Karstark       | 167.37 | #333333 |   | 2589       |
| 12 |   | 88         | Stannis warden south | 167.15 | #515151 |   | 2587       |
| 13 |   | 73         | Dorne bastard        | 114.09 | #848484 |   | 2584       |
| 14 |   | 28         | chewbacca mustafar   | 127.44 | #efefef |   | 2584       |
| 15 |   | 4          | warden south duel    | 71.89  | #111111 |   | 2584       |

Executem aquesta consulta, li donem a “Guardar resultados” i seleccionem “CSV”.